

AWID3 기반 머신러닝 모델의 실환경 배포 격차 분석과 하이브리드 WIPS 구현

이성현

Analysis of the Deployment Gap of AWID3-Based Machine Learning Models in Real-World Environments and Implementation of a Hybrid WIPS

RESEARCH NOTE

Independent study
Author: Lee Seonghyeon
Research manuscript

Key words:

Wireless Intrusion Prevention System(WIPS), XGBoost, AWID3, Real-time Active Defense, Deployment Gap, MAC Randomization

A B S T R A C T

This study presents the design, implementation, and experimental validation of a real-time Wireless Intrusion Prevention System (WIPS) tailored for IEEE 802.11 wireless networks within practical environments. While prior literature predominantly relies on offline evaluations using benchmark datasets like AWID3, the operational gap hindering real-world deployment remains largely unaddressed. In this work, we identify that initial AWID3-trained models suffer from severe false-positive behavior during live deployment, a consequence of train-serve skew induced by a heavy reliance on Target Encoding. To mitigate this issue, we developed a robust preprocessing pipeline that maps all features into rigorous numerical representations, followed by comprehensive retraining using empirical real-world traffic data. Furthermore, we observed that RF environment-dependent attributes—such as radiotap.channel.freq, radiotap.datarate, and radiotap.dbm_antsignal—vary significantly across AP channel configurations and hardware drivers, introducing additional deployment discrepancies. To overcome these limitations, the system was re-engineered using an optimized 11-feature set exclusively comprising IEEE 802.11 frame-structure elements independent of RF variations. The final architecture employs a hierarchical hybrid machine learning classifier and a sliding-window decision mechanism. In 5-fold cross-validation on the AWID3 dataset, the model achieved a ROC-AUC of 0.9994 and a false positive rate (FPR) of 1.43%. Real-world deployment yielded an FPR of 0.00%, and evaluation against unseen attack tools and novel attack vectors demonstrated strong generalization capabilities, maintaining detection rates above 89% with a minimal FPR of 0.60%.

I. 서론

1. 연구의 필요성 및 목적

가. 무선 네트워크의 구조적 취약점

IEEE 802.11 무선 네트워크는 공기 중 전파를 매체로 사용하므로, 공격자가 특별한 접근 권한 없이도 관리 프레임을 위조·주입할 수 있다는 구조적 취약점을 내재한다(Souppaya & Scarfone, 2012). Deauthentication 공격은 IEEE 802.11w 이전 표준에서 인증이 부재한 관리 프레임을 악용하여 합법적 클라이언트를 강제 연결 해제하며(Bellardo & Savage, 2003), Evil Twin 공격은 동일 SSID를 사칭하는 불법 AP를 통해 자격 증명을 탈취한다. KRACK 공격은 WPA2의 4-way 핸드셰이크 취약점을 악용하여 암호화 키를 재설치함으로써 통신 보안을 약화시킨다(Vanhoef & Piessens, 2017). 이러한 공격들은 암호화 계층 아래에서 동작하거나 정상 프로토콜 절차를 악용하기 때문에, 패킷 페이로드 기반 탐지만으로는 식별이 어렵다.

무선 침입 방지 시스템(WIPS)은 주로 규칙 기반 시그니처 매칭으로 알려진 공격 패턴을 탐지하나, MAC 주소 랜덤화나 프로토콜 퍼징과 같은 우회 기법에는 구조적으로 취약하다(Scarfone & Mell, 2007). 이를 보완하기 위해 머신러닝 기반 무선 침입 탐지 연구가 활발히 수행되어 왔으며, Kolias 외(2016)는 AWID 데이터셋을, Chatzoglou, Kambourakis, & Kolias(2021)는 IEEE 802.11w 보호 메커니즘이 적용된 엔터프라이즈 환경을 반영한 AWID3 데이터셋을 제안하여 이 분야의 연구 기반을 마련하였다.

2. 선행연구 검토 및 연구 공백

AWID3는 머신러닝·딥러닝 기반 침입 탐지 연구의 중요한 벤치마크로 활용되어 왔으나, 방법론적 측면에서 몇 가지 한계가 존재한다. 첫째, 시계열 특성을 가진 무선 트래픽을 무작위 분할할 경우 미래 정보가 학습에 유입되는 데이터 누수가 발생하여 모델 성능이 과대평가될 수 있다(Kapoor & Narayanan, 2023). 둘째, MAC/IP 주소 등 환경 종속적 식별자를 피처로 사용하면 모델이 공격 패턴이 아닌 실험 환경 고유의 정보를 학습하게 되어 다른 환경으로의 일반화 성능이 저하된다. 셋째, 대부분의 연구가 오프라인 분류 성능 향상에 집중하며, 학습된 모델을 실제 환경에 배포했을 때의 성능 변화를 체계적으로 분석하지 않는다.

본 연구는 세 번째 한계, 즉 오프라인 평가와 실환경 배포 사이의 성능 격차(Deployment Gap)에 주목한다. Target Encoding과 같이 훈련 데이터에 의존하는 범주형 인코딩 기법은 배포 환경에서 자료형·표현 방식의 미세한 불일치만으로도 인코딩 키 매칭이 실패하고, 대부분의 피쳐 값이 Global Mean으로 폴백되는 훈련-배포 분포 불일치(Train-Serve Skew)를 유발할 수 있다. Pendlebury 외(2019)는 이러한 평가 결함이 악성코드 탐지 모델의 성능을 구조적으로 과대평가함을 지적하였으나, 무선 침입 탐지 분야에서 이 현상의 발생 메커니즘을 실험적으로 규명하고 정량화한 연구는 존재하지 않는다.

3. 연구 목적 및 기여

본 연구의 기여는 새로운 탐지 알고리즘의 제안이 아니라, AWID3 기반 ML 탐지 모델의 실환경 배포 과정에서 발생하는 다단계 분포 불일치를 체계적으로 추적하고, 이를 해소하는 실용적 하이브리드 WIPS 파이프라인을 구축한 엔지니어링 사례 연구이다. 주요 기여는 다음 다섯 가지다.

1. 배포 격차 분석: Target Encoding 의존 모델(v4)이 실환경에서 FPR ~100%를 유발하는 메커니즘을 사례 기반으로 분석하고, 원인을 훈련-배포 분포 불일치로 특정한다.
2. 다단계 배포 격차 해소: 수치형 강제 변환(v5)으로 Target Encoding 의존성을 제거한 후에도 RF 환경 의존 피쳐 (radiotap.channel.freq, radiotap.datarate, radiotap.dbm_antenna)가 AP 채널 변경 및 드라이버 차이로 인한 추가 배포 격차를 유발함을 발견하고, IEEE 802.11 프레임 구조 피쳐 11개로 피쳐 집합을 재설계하여 실환경 FPR 0.00%를 달성한다.
3. 하이브리드 방어 엔진 구현: 규칙 기반 탐지와 XGBoost ML 탐지를 계층적으로 결합하고, 슬라이딩 윈도우 의사결정 엔진으로 단발성 오탐을 억제한다.
4. 실환경 능동 방어 확인: 제한된 실험실 환경에서 MAC 랜덤화 기반 규칙 우회 공격 5종을 동시 적용하여 탐지율 97.27%, FPR 0.00%를 달성하고, 능동적 Deauth 역주입을 통한 방어 효과를 확인한다.
5. 도구 무관 일반화 검증: 학습에 사용하지 않은 공격 도구(scapy)와 미학습 공격 유형(Beacon Flood, Auth Flood, Probe Flood, Association Flood)에 대해 Ground Truth 기반 정량 검증을 수행하여, 전 공격 유형에서 탐지율 89% 이상을 달성하고 하이브리드 시스템의 도구 무관 일반화 성능을 검증한다.

II. 연구 방법 (시스템 설계)

본 연구에서 제안하는 시스템은 크게 머신러닝 기반의 오프라인 학습 파이프라인과 비동기 병렬 처리 기반의 실시간 능동 방어 엔진으로 구성된다. 또한, WIPS 파이프라인은 오프라인 학습 단계와 실시간 방어 단계로 이루어진다. 오프라인 학습 단계에서는 AWID3 데이터셋과 실환경 수집 데이터를 활용하여 ML 분류기를 학습, 검증하고 모델 아티팩트를 저장한다. 실시간 방어 단계에서는 저장된 아티팩트를 로드하여 실제 무선 환경에서 패킷을 캡처하고, 규칙 기반 탐지와 ML 추론을 계층적으로 적용하여 공격을 탐지 및 차단한다.

1. 파이프라인 개요

본 연구는 다음과 같은 처리 파이프라인을 따른다(Figure 1).




Figure 1. 하이브리드 WIPS 시스템 아키텍처

tshark → 패킷 파싱 → 규칙 기반 탐지 → ML 보조 탐지 → 슬라이딩 윈도우 의사결정 → 차단 및 메트릭 기록.

규칙 기반 계층은 IEEE 802.11 관리 프레임의 구조적 특성에 기반한 결정론적 탐지를 수행하며, ML 보조 계층은 규칙에 포착되지 않는 통계적 패턴을 탐지한다. 두 계층의 결과는 슬라이딩 윈도우 기반 의사결정 엔진을 거쳐 최종 차단 여부가 결정된다.

2. 데이터 전처리 및 학습 준비

원시 패킷 데이터가 지닌 250여 개의 피처 중 데이터 누수 및 과적합을 유발하는 환경 종속적 피처를 도메인 지식에 기반하여 제거하였다. 하드웨어 식별자(BSSID, SA, DA 등 MAC 주소), 네트워크 위치 정보, 허위 상관을 유발하는 Timestamp 필드 그리고 개인정보 보호 및 실시간성을 저해하는 HTTP/Payload 데이터는 배제하였다. 초기 v4 파이프라인에서는 남은 범주형 피처에 대해 희소 카테고리 과적합을 방지하기 위해 Smoothed Target Encoding을 수행하였으나, 이 방식은 실환경 배포 시 분포 불일치 문제를 일으켜 v5에서 폐기되었다(상세 II.3절).

가. 데이터셋 구성 및 샘플링

무선 네트워크 침해 데이터셋인 AWID3(Aegean Wi-Fi Intrusion Dataset 3)를 기반으로 한다. AWID3은 실험실 환경에서 수집된 14종(정상 1종 + 공격 13종) 클래스로 구성된 무선 네트워크 트래픽 데이터셋으로, 원본 데이터는 수천만 건 이상의 레코드로 구성된다. 시스템 메모리 한계와 클래스 불균형 문제를 동시에 해소하기 위해 정상 트래픽은 데이터 청크당 최대 2,000건으로 제한하여 무작위 추출하여 데이터 비중을 조절하였다. 그리고 공격 트래픽은 공격 유형별 최대 50,000건씩 수집하는 같은 샘플링 전략을 채택하였다. 결과적으로, 이를 통해 구성된 최종 데이터셋은 총 1,466,074건이며, 정상 트래픽 922,000건과 13종 공격 트래픽 544,074건으로 이루어진다. 클래스별 구성은 SSDP(86,639건, 5.91%), Malware(69,070건, 4.71%), Evil_Twin(63,916건, 4.36%), Disas(57,892건, 3.95%) 등의 순이며, RogueAP(1,310건, 0.09%)와 SQL_Injection(2,629건, 0.18%)와 같은 극소수 클래스도 포함되어 실질적인 불균형 환경을 반영하였다.

나. 피처 선별 및 전처리

피처 정제는 두 단계로 수행되었다. 첫 번째 단계에서는 앞서 언급한 기준에 따라 MAC·IP 주소, 타임스탬프, HTTP/페이로드 관련 피처를 제거하여 약 184개의 후보 피처를 확보하였다. 두 번째 단계에서는 남은 범주형 피처에 대해 Laplace Smoothing($m=10$)을 적용한 Smoothed Target Encoding을 수행하여 수치형으로 변환하였다. 단, 인코딩 매핑은 반드시 학습 집합만을 기반으로 생성하고 검증·테스트 집합에 일방향으로 적용함으로써 데이터 누수를 원천적으로 차단하였다.

그러나 이 방식에서는 중요한 한계가 발견되었다. tshark가 실환경에서 추출하는 범주형 값의 자료형·표현 방식이 훈련 데이터와 미세하게 불일치하면서 인코딩 키 매칭이 실패하고 대부분의 피처가 Global Mean(약 0.37)으로 폴백되는 현상이 발생하였다.

다. 주요 피처 선택

본 연구는 학습 환경에 따라 두 가지 피처 집합을 독립적으로 운용한다.

(1) AWID3 오프라인 모델 피처 (v5)

정제된 184개 후보 피처에 대해 XGBoost의 Gain 기반 Feature Importance를 활용한 자동 피처 선택을 수행하였다. Gain 값을 내림차순으로 정렬하고 누적 기여도 95% 시점까지의 피처를 선택하되, 최소 15개를 보장하는 규칙을 적용하였다. 5-Fold 교차 검증 결과, 대부분의 Fold에서 15개 피처가 선택되었으며 최종 피처 집합에는 ssh.direction, udp.length, radiotap.channel.freq, wlan.country_info.fnm 등 무선 및 상위 계층 메타데이터 피처가 포함되었다. 이 피처 집합은 AWID3 데이터셋 내에서만 유효하며, 실환경 배포 시에는 tshark 출력 형식 불일치로 인해 사용할 수 없다.

(2) 실환경 재학습 모델 피처 (11개)

Target Encoding 의존성 제거 후에도 RF 환경 의존 피처가 추가 배포 격차를 유발함을 발견하여(상세 II.3절), 이를 해소하기 위해 IEEE 802.11 프레임 구조 피처만으로 구성된 11개 안정 피처 집합을 최종 설계하였다. 해당 피처는 MAC 주소·IP 주소 등 환경 종속적 식별자를 일절 포함하지 않으며, AP 채널·RF 환경·드라이버 종류와 무관하게 일관된 값이 추출된다는 특성을 지닌다(Table 1).

Table 1. 실환경 재학습 모델 피처 목록 (11개, RF 환경 독립)

범주	피처 (tshark 필드명)
프레임 제어	wlan.fc.type, wlan.fc.subtype, wlan.fc.ds, wlan.fc.retry
프레임 상태	wlan.fc.pwrmtgt, wlan.fc.moredata, wlan.fc.protected
길이/타이밍	wlan.duration, radiotap.length, frame.len
관리 프레임	wlan.fixed.reason_code

3. 배포 격차 분석과 v5 파이프라인

가. v4 파이프라인의 배포 격차

초기 설계된 v4 파이프라인은 AWID3 오프라인 평가에서 우수한 분류 성능을 달성하였다. 그러나 학습된 모델을 실제 무선 환경에 배포하였을 때, 정상 트래픽의 대부분이 공격으로 오분류되어 FPR이 100%에 근접하는 현상이 관찰되었다.

원인 분석 결과, 문제의 핵심은 Target Encoding의 훈련 데이터 의존성에 있었다. v4는 11개의 범주형 피처에 대해 Smoothed Target Mean을 적용하였는데, tshark가 실환경에서 추출하는 값의 자료형과 표현 방식이 훈련 데이터와 미세하게 불일치하면서 인코딩 키 매칭이 실패하고 대부분의 피처가 Global Mean(약 0.37)으로 폴백되었다. 그 결과 정상 패킷의 피처 분포가 학습 시점과 크게 달라져 모델이 대부분을 공격으로 분류하게 된 것이다. 이 현상은 Pendlebury 외(2019)가 지적한 훈련-서빙 분포 불일치(Train-Serve Skew) 문제의 구체적 사례이다.

나. v5 파이프라인과 실환경 재학습

배포 격차를 해소하기 위해 다음의 두 가지 접근을 병행하였다.

(1) v5 파이프라인 - 수치형 강제 변환

Target Encoding을 전면 제거하고, 모든 피처를 `pd.to_numeric(errors='coerce').fillna(0)`으로 수치형으로 강제 변환하였다. 이를 통해 훈련 데이터에 대한 인코딩 의존성을 원천적으로 제거하여 배포 환경의 자료형·표현 방식 차이에 무관하게 일관된 피처 값을 보장하였다.

(2) 실환경 재학습 모델

실제 무선 환경에서 직접 수집한 정상 트래픽과 공격 트래픽을 기반으로 이진 분류기를 재학습하였다. 훈련 데이터와 배포 환경의 피처 분포를 일치시킴으로써 오프라인 학습 모델이 실환경에서 겪는 분포 불일치를 근본적으로 해소하는 방향을 취하였다.

(3) RF 환경 피처 의존성과 11개 안정 피처 집합

v5 파이프라인 도입 이후에도 실환경 배포 시 추가적인 배포 격차가 관찰되었다. 원인 규명을 위해 학습 데이터(CSV)와 실시간 tshark 추출값의 피처별 분포를 정량 비교한 결과, 세 가지 RF 환경 의존 피처에서 심각한 불일치가 확인되었다.

`radiotap.channel.freq`는 학습 시 AP 채널 7(2,442 MHz)에서 수집된 데이터로 학습되었으나, 실환경 배포 시 AP가 채널 3(2,422 MHz)으로 변경되면서 모델이 학습 시 정상으로 관측하지 못한 주파수 값을 모두 공격으로 분류하였다. `radiotap.dbm_antsignal`은 학습 데이터에서 nonzero 비율이 97.7%에 달하였으나, 실환경 tshark 캡처에서는 드라이버 설정 차이로 해당 필드가 0.0% nonzero로 추출되어 모든 정상 패킷의 해당 피처 값이 학습 분포와 전혀 다른 값(0)을 가지게 되었다. `radiotap.datarate` 또한 학습 분포(평균 12.772 Mbps)와 실시간 분포(평균 8.337 Mbps)간에 현저한 차이를 보였다.

이를 해소하기 위해 세 RF 의존 피처를 완전히 제거하고 AP 채널·드라이버 종류·RF 환경과 무관하게 일관된 값이 추출되는 IEEE 802.11 프레임 구조 피처만으로 재구성한 11개 안정 피처 집합(Table 1)을 설계하였다. 재학습 결과 오프라인 5-Fold CV ROC-AUC는 RF 피처 포함 모델의 0.9997에서 0.9982로 소폭 하락하였으나, 실환경 FPR이 0.00%로 완전히 해소되었다. 이는 오프라인 분류 성능의 미미한 손실($\Delta AUC \approx 0.0015$)을 감수하고 실환경 배포 안정성을 확보한 결과이다.

4. 머신러닝 모델 학습

클래스 간의 극심한 데이터 불균형 문제를 해결하기 위해, 학습 단계에서 Balanced Sample Weight를 적용한(He & Garcia, 2009) XGBoost 기반의 다중 분류 모델을 구축하였다(Chen & Guestrin, 2016). 이와 함께 Isotonic Calibration 기법을 적용하여(Niculescu-Mizil & Caruana, 2005) 모델이 출력하는 확률값의 신뢰도를 보정하였다. 최종적으로 모델의 분류 임계치는 탐지율에 2배의 가중치를 부여하는 F2-Score를 최대화하되(van Rijsbergen, 1979), 실환경 운용 가능성을 고려하여 오탐률이 5% 미만인 되도록 튜닝되었다.

가. 분류 모델 학습 및 확률 보정

선택된 피처를 입력으로 XGBoost 다중 분류기를 학습하였다. 하이퍼파라미터는 `max_depth=8`, `learning_rate=0.05`, `n_estimators=200`으로 설정하였으며, Early Stopping(10라운드 미개선 시 중단)을 통해 과적합을 방지하였다. 또한, 클래스 불균형 대응을 위해 클래스별 역빈도 비례의 Balanced Sample Weight를 학습 샘플에 부여하였다. 그 후, 학습된 모델의 출력 확률을 별도의 Calibration Set에 대해 Isotonic Regression을 적용하여 보정하였으며, 이 단계에서 Early Stopping 검증 집합과 보정 집합을 분리하여 동일한 데이터가 중복 사용되는 Double Dipping 문제를 방지하였다.

나. 탐지 임계치 설정

보정된 모델의 출력 확률에서 Attack Score를 $1 - P(\text{Normal})$ 로 정의하고, 별도의 Threshold Tuning Set에서 0.01 간격의 그리드 탐색을 수행하였다. 각 임계치 후보에 대해 F2-Score를 계산하고 $\text{FPR} < 5\%$ 제약을 만족하는 범위 내에서 F2-Score를 최대화하는 임계치를 선택하였다. 5개 Fold에서 산출된 최적 임계치는 0.3565, 0.2179, 0.4159, 0.2872, 0.0793으로 분산이 있으나(표준편차 0.1167), 이는 각 Fold의 클래스 분포와 캘리브레이션 결과에 따른 자연스러운 변동이다. 실험 환경 배포 시에는 5개 Fold의 평균값(0.2713)을 단일 임계치로 사용하거나, Fold 5의 모델을 채택하여 해당 임계치(0.0793)를 적용하는 방식을 취하였다.

5. 규칙 기반 탐지 계층

규칙 기반 탐지 계층은 IEEE 802.11 관리 프레임의 구조적 특성을 이용한 결정론적 탐지를 수행한다. 탐지 대상 공격 유형과 임계값은 다음 표와 같다(Table 2).

Table 2. 규칙 기반 탐지 조건 및 임계값

공격 유형	탐지 조건	임계값
Deauthentication Flood	<code>wlan.fc.subtype == 12</code>	3초 내 10회
Disassociation Flood	<code>wlan.fc.subtype == 10</code>	3초 내 10회
Evil Twin	동일 SSID, 다수 BSSID 관측	임계 RSSI 편차
Beacon/Probe/Auth/Assoc Flood	동일 subtype, 신규 MAC 급증	3초 내 신규 MAC 15개

또한 Beacon Flood, Probe Request Flood, Authentication Flood, Association Request Flood와 같은 관리 프레임 Flood 공격을 탐지하기 위해 빈도 기반 규칙을 추가하였다. 개별 Beacon/Probe 프레임은 정상 트래픽과 동일한 구조를 가지므로 단일 패킷 수준의 분류로는 탐지가 어렵다. 이를 해소하기 위해 세션 내 최초 등장하는 신규 MAC 주소의 출현 빈도를 3초 슬라이딩 윈도우로 추적하고, 동일 프레임 서브타입에서 신규 MAC이 15개 이상 관측되면 Flood 공격으로 판정한다. 정상 환경의 기존 장치는 반복 등장하여 카운트에서 제외되므로, 랜덤 MAC을 사용하는 Flood 공격만 선택적으로 탐지된다. 시스템 시작 후 10초간은 주변 MAC을 학습하는 워밍업 구간으로 운용하여 초기 오탐을 방지하며, Flood 상태가 감지되면 5초간 유지하여 지속적 공격에 대한 연속 탐지를 보장한다.

오탐 방지를 위해 다음과 같은 필터를 적용하였다.

- Broadcast MAC(`ff:ff:ff:ff:ff:ff`, `00:00:00:00:00:00`) 제외
- Multicast MAC(`01:xx:xx:xx:xx:xx`) 제외
- SSID 누락 프레임 제외

6. ML 보조 탐지 계층

ML 보조 계층은 3초 슬라이딩 윈도우 내에서 규칙 기반 탐지에 포착되지 않은 패킷에 대해 XGBoost 이진 분류기를 적용한다. 사용된 피처는 RF 환경 의존 피처를 배제하고 IEEE 802.11 프레임 구조 피처만으로 구성된 11개 안정 필드로 구성된다.

- 프레임 제어: `wlan.fc.type`, `wlan.fc.subtype`, `wlan.fc.ds`, `wlan.fc.retry`
- 프레임 상태: `wlan.fc.pwrmtgt`, `wlan.fc.moredata`, `wlan.fc.protected`
- 길이/타이밍: `wlan.duration`, `frame.len`, `radiotap.length`
- 관리 프레임: `wlan.fixed.reason_code`
- 분류기는 Isotonic Calibration이 적용된 XGBoost 이진 분류기이며, 최종 Attack Score는 $1 - P(\text{Normal})$ 로 산출된다.
- 분류 임계값은 F2-Score 기반 튜닝을 통해 설정된다.

7. 실시간 탐지 시스템 구현

오프라인에서 학습된 최적의 모델 아티팩트를 실시간 방어 엔진에 이식한다. 실시간 탐지 엔진은 tshark 기반의 서브프로세스를 통해 패킷을 캡처하고, 이를 비동기 큐에 적재한다. 다수의 워커 스레드가 병렬로 큐의 패킷을 꺼내어 추론을 수행함으로써 캡처와 추론 간의 병목을 해소한다.

가. 패킷 수집 및 추론 구조

학습된 모델을 실환경에 배포하기 위한 비동기 병렬 처리 구조의 실시간 방어 엔진을 설계하였다. 패킷 수집은 tshark 서브프로세스가 담당하며, 캡처된 패킷을 최대 20,000건 용량의 Queue에 적재한다. 큐가 포화 상태일 경우 신규 패킷을 드롭하는 Backpressure 메커니즘을 적용하여, 패킷 캡처 스레드가 ML 추론 지연에 의해 차단되는 현상을 방지하였다. ML 추론은 4개의 워커 스레드가 병렬로 큐에서 패킷을 소비하며 수행한다. 각 워커는 실시간 패킷에서 학습 피쳐와 동일한 구조의 특징값을 추출하고 모델에 입력하여 Attack Score를 산출한다.

나. 슬라이딩 윈도우 의사결정

단일 패킷 수준의 오탐이 정상 사용자의 차단으로 이어지는 것을 방지하기 위해 슬라이딩 윈도우 기반 의사결정 엔진을 도입하였다. 동일 MAC 주소에서 동일 공격 유형이 3초 슬라이딩 윈도우 내에서 사전 정의된 임계 횟수를 초과하는 경우에만 최종 차단을 결정한다. 공격 계열별 임계값은 다음과 같이 차등 적용된다.

- Flooding 계열(Deauth, Auth 등): 3초 내 10회 이상 누적 탐지 시 차단
- Impersonation 계열(Evil Twin 등): 3초 내 5회 이상 누적 탐지 시 차단

Flooding 계열의 임계값은 실환경 실험 데이터에 기반하여 설정되었다. 활성 클라이언트 3대가 존재하는 AP 과부하 환경(실험 3)에서, 정상 클라이언트가 ML에 의해 ATTACK으로 오탐된 최대 빈도는 3초 내 6회(재전송 프레임의 연속 오분류)였다. 반면 고정 MAC 공격자의 탐지 누적은 3초 내 15회 이상에 달하였다. 임계값 10은 정상 트래픽 최대치(6회)와 공격 트래픽 최소치(15회) 사이에 위치하여, 오차단을 방지하면서 지속적 공격에 대해 수 초 이내 대응을 가능하게 한다. Impersonation 계열은 SSID·BSSID 매칭 기반 탐지이므로 정상 트래픽의 구조적 오탐 확률이 낮아 5회로 설정하였으며, 실험에서 비공격 구간의 Evil Twin 오탐은 단일 건에 그쳤다.

아래의 Table 3는 실환경 실험(실험 3 및 일반화 실험)에서 측정된 3초 윈도우 내 탐지 누적 빈도를 요약한 것이다.

Table 3. 슬라이딩 윈도우 차단 임계값의 실험적 근거

구분	3초 윈도우 내 최대 탐지 횟수	비고
정상 클라이언트 (AP 과부하 환경)	6회	ML 연속 오탐 (재전송 프레임)
비공격 구간 주변 장치	3회	규칙 기반 오탐
차단 임계값 (Flooding)	10회	
고정 MAC 공격자	15회	규칙 + ML 병행 탐지

8. 능동 방어 계층

본 연구에서 제안한 시스템의 실증 실험은 능동 방어에 사용된 AR9271 USB 무선 랜카드의 하드웨어 사양을 고려하여 2.4GHz 환경을 대상으로 수행되었다. 차단 결정 시 공격 유형에 따라 다음과 같이 차별적 방어가 수행된다.

- Flooding 계열: AR9271 무선 랜카드를 통해 공격자 MAC으로 Deauthentication 프레임을 역주입하는 능동 방어를 수행한다.
- Impersonation 계열: Linux iptables를 통해 MAC 기반 패킷 드롭 규칙 적용, aireplay-ng를 통해 공격자에게 Deauth 프레임 역주입하여 OS 계층에서 접속을 원천 차단한다.

최종적으로 공격이 확인되면 시스템은 Linux Netfilter 기반의 패킷 필터링 정책을 적용하여 공격 트래픽을 차단하고, L2 계층에서는 AR9271 무선 랜카드를 통해 보호 목적의 관리 프레임 기반 대응을 수행한다.

III. 실험 설계 및 결과

1. 실험 데이터 및 평가 방법

본 연구는 AWID3 데이터셋 중 정상 트래픽 92만여 건과 13종의 악성 공격 트래픽 54만여 건을 균형 있게 서브샘플링하여 총 1,466,074건의 실험 데이터를 구축하였다. 데이터 분할 시 Run-length 분석 및 분포 동일성 검증을 통해 시간적 편향이 미미함을

확인한 뒤 Stratified 5-Fold CV를 적용하였다(Kohavi, 1995). 각 학습 구간 내부에서 클래스 불균형 완화를 위해 Stratified 방식의 검증 전략을 적용하였다. 성능 측정은 ROC-AUC, System FPR, 공격 유형별 재현율을 지표로 활용하였다.

2. 모델 성능 결과

AWID3 데이터셋에 대한 5-Fold CV 결과, v4 파이프라인(Smoothed Target Encoding 기반)은 통합 ROC-AUC 0.9994, Accuracy 95.04%, Macro F1-Score 0.8764의 분류 성능을 나타냈다(Table 4). 수치형 강제 변환을 적용한 v5 파이프라인 또한 동일 데이터셋에서 ROC-AUC 0.9986, System FPR 3.47%의 오프라인 성능을 나타냈으며, 두 파이프라인의 차이는 오프라인 성능이 아니라 실환경 배포 가능성에 있다. 전체 정상 트래픽 대비 단일 패킷 오탐은 평균 1.43%로 매우 낮게 통제되었다. 13개 공격 유형 중 L7 응용 계층 공격인 SQL_Injection은 L2 프레임 피처로 탐지 불가능한 범위 외 사례로 분류하고, Disas는 규칙 기반 계층이 전담하는 유형으로 구분하였다. ML 탐지 범위 내 11개 공격 유형 전체에서 탐지율 90% 이상을 달성하였다.

Table 4. AWID3 데이터셋 클래스별 탐지율 (Stratified 5-Fold CV 통합 결과, v4 파이프라인)

공격 유형	Support	TP	탐지율(DR)	비고
(Re)Assoc	5,502	5,498	99.93%	ML 탐지
Botnet	50,438	45,471	90.15%	ML 탐지
Deauth	38,942	38,569	99.04%	ML + 규칙 병행
Disas	57,892	10,438	18.03%	‡규칙 기반 이관
Evil_Twin	63,916	63,115	98.75%	ML 탐지
Kr00k	54,006	51,133	94.68%	ML 탐지
Krack	49,990	49,990	100.00%	ML 탐지
Malware	69,070	68,718	99.49%	ML 탐지
RogueAP	1,310	1,310	100.00%	ML 탐지 ‡
SQL_Injection	2,629	1,741	66.22%	★ML 범위 외
SSDP	86,639	86,639	100.00%	ML 탐지
SSH	11,882	11,543	97.15%	ML 탐지
Website_spoofing	51,858	50,417	97.22%	ML 탐지
결과				
Normal (TNR)	922,000	908,791	98.57%	
System FPR	--	--	1.43%	
ROC-AUC	--	--	0.9994	

‡Disas는 Kr00k 등 인접 공격 유형과 L2 프레임 구조가 유사하여 ML 단독 탐지율이 낮다. 하이브리드 WIPS의 규칙 기반 계층(wlan.fc.subtype=10 결정론적 매칭)이 이를 100% 커버하므로, 최종 시스템의 Disas 탐지율은 100%이다.

★SQL_Injection은 응용 계층(L7) 공격으로, 무선 프레임 수준의 L2 피처로는 공격 여부를 구분할 수 없다. 이는 탐지 범위 외 사례이며 ML 성능 평가에서 제외한다.

‡RogueAP(n=1,310)의 100% 탐지율은 소표본 특성상 통계적 신뢰구간이 넓으며, 하이브리드 계층에서는 규칙 기반으로도 병행 탐지된다.

그림 2. AWID3 데이터셋 클래스별 탐지율 (Stratified 5-Fold CV)




Figure 2.

클래스별 탐지율 (Stratified 5-Fold CV 통합 결과)

AWID3

ML 탐지 범위 내 11개 공격(SQL_Injection·Disas 제외)의 탐지율은 90.15%~100.00% 범위에 분포하며, 11종 전체에서 90% 이상을 달성하였다. Disassociation Flood는 혼동행렬 분석 결과 47,222건이 Kr00k로 오분류되었는데, 두 공격 유형이 IEEE 802.11 프레임 구조 수준에서 유사한 패턴을 공유하기 때문이다. 그러나 하이브리드 WIPS에서 Disas는 규칙 기반 계층(wlan.fc.subtype=10)이 결정론적으로 탐지하므로, ML의 18.03%라는 수치는 하이브리드 시스템의 실질적 Disas 탐지율(100%)을 대표하지 않는다. SQL_Injection은 TCP/UDP 페이로드 내부 패턴으로 구별되는 L7 공격으로, L2 무선 프레임 피쳐로는 정상 데이터 트래픽과 구조적으로 구분이 불가하다. 이는 L2 탐지 시스템의 고유한 범위 제한이며, 하이브리드 계층 설계의 필요성을 실증적으로 뒷받침한다.

Krack, SSDP, (Re)Assoc 등 공격은 소프트웨어 인젝션 특유의 radiotap.length 시그니처가 명확하여 탐지율 99~100%를 달성하였다 (Figure 2).

3. 실환경 적용 시 모델 비교

동일 데이터셋에서 순수 ML 단독 모델, 순수 규칙 기반 모델, 그리고 제안하는 하이브리드 모델의 성능을 비교 평가하였다(Table 5).

Table 5. 탐지 방식별 실환경 성능 비교

구분	오프라인 AUC	실환경 FPR	탐지 대상	배포 가능
Pure ML (v4, Target Encoding)	0.9994	~100%	AWID3 13종	x
Pure ML (v5, 수치형 강제 변환)	0.9986	~100%	AWID3 13종	x
Hybrid (규칙 + 실환경 ML, RF피쳐 포함)	0.9997†	~100%	규칙 3종 + 5종	x
Rule-only	--	0.00%	Deauth/Disas/Evil Twin (3종)	v
Proposed Hybrid (규칙 + 실환경ML, 11피쳐)	0.9982*	0.00%	규칙 3종 + 학습된 5종 + 미지 공격 일반화	v

*0.9982는 실환경 수집 데이터에 대한 11피쳐 모델의 5-Fold CV ROC-AUC (IV.2 참조). AWID3에 대한 직접 평가가 아니므로 v4/v5와 직접 비교는 불가하다.

†RF피쳐 포함(14피쳐) 모델은 동일 데이터에서 5-Fold CV ROC-AUC 0.9997로 11피쳐 모델(0.9982)보다 오프라인 성능이 높으나, 실환경 FPR이 ~100%로 배포 불가하다. 원인: AP 채널 변경(2,442→2,422 MHz)으로 channel.freq 분포 불일치, dbm_antsignal 0% 추출로 학습 분포와 전혀 다른 값. 즉 RF피쳐는 오프라인 AUC를 높이지만 배포 안정성을 훼손한다.

Pure ML (v4)의 실환경 FPR ~100% 원인: Target Encoding 키 매칭 실패 → 전 피쳐가 Global Mean(0.37)으로 폴백.

Pure ML (v5)의 실환경 FPR ~100% 원인: AWID3 학습 피쳐(ssh.direction 등)가 실환경 tshark에서 추출 불가.

IV. 실환경 실험 및 고찰

1. 실험 환경 구성 및 시나리오

실환경 성능 검증을 위해 Kali Linux 기반의 공격 노드와 Python 기반 방어 엔진이 구축된 테스트베드를 구성하였다.

Table 6. 실험 환경 구성

구성 요소	사양
방어 대상 AP	IEEE 802.11n, SSID: TOTOLINK_A3002RU
AP BSSID	40:EE:15:03:9D:6C, Channel 7 (2.442 GHz)
정상 클라이언트	스마트폰, 태블릿, 노트북 (3대, 실제 브라우징/스트리밍)
공격/방어 노드	Kali Linux, wlan1mon (모니터 모드)
패킷 캡처	tshark, 모니터 모드
방어엔진	Python 3.13, XGBoost 2.x
공격 구도	mdk4 (Auth/EAPOL/Beacon/Fuzzer/Probe Flood)
차단 도구	aireplay-ng -0 64 (Deauth 역주입)

2. 실환경 재학습

AWID3 기반 모델의 배포 격차를 해소하기 위해, 실제 AP 환경에서 수집한 트래픽으로 ML 모델을 재학습하였다. 정상 트래픽은 3대의 클라이언트가 실제 브라우징 및 스트리밍을 수행하는 300초 구간에서 수집하였으며, 공격 트래픽은 규칙 기반 계층이 포착하지 못하는 유형으로 한정하여 수집하였다(Table 7).

Table 7. 실환경 재학습 데이터

구분	수집 방법	샘플 수
정상 트래픽	클라이언트 3대 일반적 사용 (300s)	67,989
공격 트래픽	규칙 우회 공격 5종 (300s)	234,206

재학습에 사용한 공격 유형은 Authentication DoS(mdk4 -a), EAPOL DoS(mdk4 -e), Beacon Flood(mdk4 -b), Packet Fuzzer(mdk4 -f), Probe Request Flood(mdk4 -p)의 5종으로, 이들은 모두 Deauth/Disas/Evil Twin 규칙을 우회하며 소스 MAC을 패킷마다 무작위로 변경하는 특성을 가진다. 11개 안정 피쳐 기반 모델의 재학습 결과, Stratified 5-Fold CV에서 ROC-AUC 0.9982(표준편차 0.0001), 평균 탐지율 98.39%를 달성하였다.

3. 실험 시나리오

세 차례의 실환경 실험을 수행하였다. 실험 1·2는 시스템의 기본 동작을 검증하는 예비 실험이며, 실험 3이 본 연구의 정식 검증 실험이다.

- 실험 1 (예비): aireplay-ng Deauth Flood, 58초, 클라이언트 없는 환경
- 실험 2 (예비): mdk4 Auth Flood + Beacon Flood 혼합, 300초, 클라이언트 없는 환경
- 실험 3 (정식): 활성 클라이언트 3대 환경에서 MAC 랜덤화 규칙 우회 공격 5종 동시 적용, 300초, 실환경 재학습 모델 + MAC 기반 그라운드 트루스 로깅 적용

실험 3의 공격 유형은 모두 규칙 기반 탐지 계층(Deauth subtype 12, Disas subtype 10, Evil Twin SSID 중복)을 우회하도록 설계되어, ML 보조 계층의 독립적 탐지 기여를 측정하는 데 적합한 조건이다.

4. 정량 결과

세 차례 실험의 정량적 결과는 (Table 8)과 같다.

Table 8. 실환경 공격 실험 정량 결과

항목	실험 1 (Deauth, 58s)	실험 2 (복합, 300s)	실험 3 (정식, 300s)
총 캡처 패킷	18,269	171,826	171,958
Control 프레임 제외	11,871 (65.0%)	117,791 (68.5%)	5,058 (2.9%)
처리 가능 패킷	6,398	54,035	166,900
탐지 - Deauth (규칙)	2,391	16,974	58
탐지 - Disas (규칙)	36	113	0
탐지 - Evil Twin (규칙)	0	2,447	331
탐지 - ML 보조	286	12,443	161,958
총 탐지 수	2,713	31,977	162,347
탐지율	42.40%	59.18%	97.27%
FPR	0.00%	0.00%	0.00%
Precision	100%	100%	100%
평균 탐지 지연	0.16 ms	0.52 ms	1.54 ms
P95 탐지 지연	0.45 ms	2.64 ms	9.89 ms
활성 클라이언트	없음	없음	3대
ML 탐지 비중	10.5%	38.9%	99.8%
차단된 MAC	1	3	0 (MAC 랜덤화)

실험 3에서 ML 분류기가 전체 탐지의 99.8%를 담당한 것은, 적용된 5종 공격이 모두 규칙을 우회하는 유형이었기 때문이다.

예비 실험(실험 1·2) 대비 탐지율이 42~59%에서 97.27%로 대폭 향상된 것은 실환경 재학습 모델의 효과이다. 본 연구에서 "탐지율"은 처리 가능 패킷 중 시스템이 공격으로 분류한 패킷의 비율을 의미하며, "FPR"과 "Precision"은 시스템 수준의 차단 결정을 기준으로 산출되었으며, 패킷 단위 ML 예측의 정확성을 보장하지 않는다. mdk4 공격 도구의 MAC 랜덤화로 인해 패킷 단위 그라운드 트루스 매칭이 제한되어, 162,347건의 ML 탐지 각각이 진정한 공격 패킷인지 여부에 대한 완전한 검증은 본 실험 범위에서 수행되지 않았다.

5. 그라운드 트루스 분석

실험 3에서는 사전에 등록된 공격자 MAC 및 클라이언트 MAC을 기반으로 패킷별 그라운드 트루스를 기록하였다(Table 9).

Table 9. 실험 3 그라운드 트루스 분석

지표	값	비고
GT_TP	0	mdk4 MAC 랜덤화로 공격자 실제 MAC 미출현
GT_FP	8	클라이언트 패킷 43건 중 오탐
GT_TN	35	
GT_FN	0	
GT_FPR	18.6%	소표본(43건) 기준, 통계적 유의성 제한

GT_TP=0은 mdk4가 소스 MAC을 패킷마다 무작위 변경하여 등록된 공격자 MAC이 실제 패킷에 나타나지 않기 때문이다. GT_FP=8은 AP 과부하 상태에서 클라이언트 재전송 프레임이 공격 패턴과 유사한 피쳐 값을 가질 수 있음을 시사한다. 그라운드 트루스 검증 대상이 43건에 그친 이유는, 사전 등록된 클라이언트 MAC과 정확히 일치하는 패킷만 검증 집합에 포함시켰기 때문이다. 현대 스마트폰·태블릿의 MAC 랜덤화 기능, 그리고 포화 공격 환경에서의 캡처 손실로 인해 실제 클라이언트 트래픽의 대부분은 GT 매칭에서 제외되었다. 단, 클라이언트 관찰 샘플이 43건으로 소표본이므로 GT_FPR 18.6%의 통계적 신뢰구간이 넓다는 점에서 직접적 비교에 한계가 있다. 한편, Table 8의 FPR 0.00%는 시스템 수준의 차단 오탐률로, 슬라이딩 윈도우 임계값을 초과하여 실제 차단 결정으로 이어진 정상 클라이언트 패킷이 없었음을 의미한다. GT_FPR 18.6%는 패킷 단위 ML 예측 오류율로, 개별 패킷이 공격으로 분류되었으나 슬라이딩 윈도우 필터에 의해 차단으로 이어지지 않은 경우를 포함한다. 두 지표는 측정 단위(시스템 차단 vs. 패킷 단위 예측)가 상이하므로 직접 비교는 적절하지 않다.

6. 차단 메커니즘 분석

차단 메커니즘 분석 결과는 다음과 같으며, 실험 3의 실행 화면을 함께 제시한다(Table 10, Figure 3).

Table 10. 실험 3 차단 메커니즘 분석

지표	결과
MAC 블랙리스트 차단	0건 (MAC 랜덤화로 임계값 미도달)
능동적 Deauth 역주입	탐지 이벤트마다 자동 실행
공격 도구 AP 응답률	0% ("AP responded on 0 of N probes")
공격 도구 연결 성공률	0% ("Status: No Response")




Figure 3. 실험 3 실행 화면

mdk4와 같이 소스 MAC을 패킷마다 변경하는 도구에 대해 MAC 블랙리스트 방식은 단일 MAC이 임계값에 도달하지 못하므로 원천적으로 무효화된다. 반면, ML 탐지 이벤트에 연동된 능동적 Deauth 역주입은 MAC에 무관하게 AP 접근을 교란하여 공격 도구의 응답률을 0%로 낮추었다. 이는 MAC 기반 차단이 구조적 한계와 패턴 기반 능동 대응의 보완적 역할을 실험적으로 입증한다.

7. 실험의 제한점

본 실험은 능동 방어에 사용된 AR9271 USB 무선 랜카드의 하드웨어 사양상 2.4GHz 단일 채널 환경에서 수행되었다. 따라서 다채널 환경에서의 채널 호핑 시 패킷 손실률 및 탐지 누락에 대한 정량 분석은 본 실험 범위를 벗어나며, 별도의 측정이 필요하다. 또한 정식 검증 실험(실험 3)은 300초의 단일 세션으로 진행되었으므로, 장시간 운용 시 발생할 수 있는 메모리 누수·큐 포화·모델 드리프트 등의 안정성 요인은 본 결과에 포함되지 않는다.

8. 미학습 공격 도구 및 유형에 대한 일반화 실험

실환경 재학습 모델이 학습에 전혀 사용되지 않은 공격 도구와 공격 유형에 대해 일반화 성능을 보이는지 검증하기 위한 추가 실험을 수행하였다. 실험 환경은 Table 6와 동일하되, 공격 도구를 mdk4 대신 Python 패킷 조작 라이브러리 scapy로 교체하였다. scapy는 실험 3의 재학습 데이터 수집 및 모델 학습에 일절 사용되지 않은 미학습 도구이다. 실험은 활성 클라이언트가 없는 환경에서 약 120초간 수행되었으며, WIPS가 캡처한 총 패킷은 8,932건(처리 가능 7,893건)이다.

가. 실험 설계

공격 유형은 다음과 같이 구성하였다.

- scapy Deauthentication Flood: 관리 프레임 subtype=12 연속 주입
- scapy Beacon Flood: 관리 프레임 subtype=8, 무작위 SSID 연속 주입
- scapy Authentication Flood: 관리 프레임 subtype=11 연속 주입 (MAC 랜덤화)
- scapy Probe Request Flood: 관리 프레임 subtype=4 연속 주입
- scapy Association Request Flood: 관리 프레임 subtype=0 연속 주입

각 공격 유형당 200패킷을 순차 전송하고, 공격 간 5초 대기기를 두어 시간적으로 분리하였다. 공격 스크립트는 전송 수와 시작·종료 타임스탬프를 JSON으로 기록하며, WIPS의 패킷별 상세 로그(타임스탬프, MAC, 탐지 결과)와 시간 윈도우 매칭을 통해 공격 유형별 Ground Truth 탐지율을 산출하였다. 수신기준 탐지율은 탐지 수를 (탐지 수 + 미탐지 추정 수)로 나누어 계산하며, 미탐지 추정은 공격 윈도우 내 NORMAL로 분류된 단일등장 MAC(랜덤 MAC 공격의 특성상 1회만 출현하는 MAC은 공격 패킷일 가능성이 높음)의 수로 산출하였다.

본 실험에서 총 캡처 패킷은 8,932건이며, 이 중 처리 가능 패킷은 7,893건(88.4%)이었다. 전체 실험 시간은 약 120초이며, 평균 탐지 지연은 0.47 ms, P95 탐지 지연은 1.07 ms를 기록하였다.

나. 결과

scapy Deauth Flood는 규칙 기반 계층(subtype=12 결정론적 탐지)이 포착하여 수신기준 탐지율 97.9%를 달성하였다. Beacon Flood, Probe Flood, Association Flood에 대해서는 신규 MAC 빈도 기반 Flood 탐지 규칙이 주 탐지 계층으로 작동하였으며, Authentication Flood는 ML 보조 계층과 Flood 규칙이 병행하여 탐지하였다. Ground Truth 기반 정량 결과는 다음과 같다(Table 11).

Table 11. 미학습 공격 도구 유형에 대한 일반화 실험 결과 (Ground Truth 검증)

공격 유형	전송	탐지 계층	수신기준 DR
Deauth Flood	200	규칙기반	97.9%
Beacon Flood	200	Flood 규칙	89.9%
Auth Flood	200	ML + Flood	99.7%
Probe Flood	200	Flood 규칙	93.0%
Assoc Flood	200	Flood 규칙	98.4%
FPR (공격 윈도우 외)			0.60%
Precision (시스템 수준)			100%
평균 탐지 지연			0.47 ms
P95 탐지 지연			1.07 ms

전 공격 유형에서 수신기준 탐지율 89% 이상을 달성하였으며, 계층별 탐지 기여를 정량적으로 분석한 결과는 다음과 같다. Deauth Flood는 규칙 기반 계층이 181건을 탐지하였고 ML이 9건을 보조하였다. Auth Flood에서는 ML이 1,242건, Flood 규칙이 186건을 탐지하여 ML 보조 계층의 기여가 지배적이었다. Auth Flood의 탐지 수(1,428건)가 전송 수(200건)를 초과한 것은, 공격 패킷이 유발한 AP의 인증 응답 등 연쇄 프레임까지 비정상 radiotap.length 패턴으로 탐지되었기 때문이다. Beacon Flood(Flood 규칙 163건, ML 6건)와 Probe Flood(Flood 규칙 170건), Assoc Flood(Flood 규칙 188건)에서는 Flood 규칙이 주 탐지 계층으로 작동하였다. Beacon Flood(89.9%)와 Probe Flood(93.0%)의 탐지율이 상대적으로 낮은 이유는, Flood 규칙의 신규 MAC 임계값(15개) 도달 전 초기 패킷이 미탐지되는 워밍업 구간이 존재하기 때문이다. FPR 0.60%는 공격 윈도우 외 구간에서 관측되었으며(정상 3,157건 중 19건 오탐), 주변 신규 장치의 관리 프레임이 Flood 임계값에 일시적으로 도달한 결과로 분석된다.

다. 분석: radiotap.length 기반 도구 무관 탐지 메커니즘

피쳐 중요도 분석(Gain 기준) 결과 radiotap.length가 Gain=9,899.3으로 압도적 1위를 차지하였으며, 2위인 wlan.fc.type(Gain=156.0)과 비교하여 약 63배의 차이를 보였다(Table 12). 이는 모델이 소프트웨어 기반 패킷 인젝션 도구 특유의 RadioTap 헤더 길이 패턴을 공격 식별의 핵심 신호로 학습하였음을 시사한다. 합법적 IEEE 802.11 드라이버는 radiotap.length를 하드웨어 사양에 따라 일관된 값으로 보고하는 반면, scapy·bettercap·mdk4 등 소프트웨어 인젝션 기반 도구는 상이한 radiotap.length 값을 생성한다. 학습 데이터에 포함된 mdk4 공격의 이 패턴이 새로운 인젝션 도구에도 동일하게 적용된 결과, Auth Flood·Assoc Flood와 같이 radiotap.length 차이가 명확한 공격 유형에서 99% 이상의 탐지율을 달성하였다. 반면 Beacon·Probe Flood는 정상 트래픽과 개별 패킷 수준의 피쳐 차이가 작아 ML 단독으로는 탐지율이 낮았으나, 신규 MAC 빈도 기반 Flood 규칙과의 결합으로 89~93%까지 향상되었다. 이는 하이브리드 아키텍처에서 ML 계층과 규칙 기반 계층이 상호 보완적 역할을 수행함을 실험적으로 확인한다.

Table 12. 실환경 재학습 모델 피쳐 중요도 (상위 5개, Gain 기준)

순위	피쳐	Gain
1	radiotap.length	9,899.3
2	wlan.fc.type	156.0
3	frame.len	43.6
4	wlan.duration	37.1
5	wlan.fc.subtype	30.9

Gain 기반 피쳐 중요도 분석을 보완하기 위해 SHAP(SHapley Additive exPlanations; Lundberg & Lee, 2017) 분석을 수행하였다. SHAP은 게임이론의 Shapley value에 기반하여 각 피쳐가 개별 예측에 미치는 기여도를 이론적으로 엄밀하게 분해한다.

전체 데이터에서 5,000건을 무작위 추출하여 TreeExplainer를 적용한 결과, radiotap.length의 mean |SHAP value|은 7.76으로 2위 wlan.duration(0.59) 대비 약 13배에 달하였다(Figure 5). SHAP summary plot은 방향성 정보도 제공하는데, radiotap.length 값이 높은 샘플(36, 정상 NIC)은 SHAP 값이 음수(정상 방향)로, 낮은 샘플(12~13, 인젝션 도구)은 양수(공격 방향)로 분포하여, 모델이 radiotap.length의 이진 분리 패턴을 학습하였음을 시각적으로 확인하였다. 이는 Gain 기반 분석(Table 12)의 결론과 일치하며, 이론적

근거를 보강한다.

radiotap.length의 압도적 Gain 값은 해당 피처가 소프트웨어 인젝션 도구의 tool fingerprint로 기능함을 시사한다. 실제로 학습 데이터의 분포를 분석한 결과, 정상 트래픽의 radiotap.length는 36(96.1%)에 집중되는 반면, mdk4 공격 트래픽은 12(48.4%)와 13(48.0%)에 집중되어 거의 완벽한 이진 분리가 관찰되었다. radiotap.length 단일 피처만으로 5-Fold CV AUC 0.9829를 달성하여, 모델의 해당 피처 의존도가 높음을 확인하였다. 그러나 radiotap.length를 제거한 10피처 모델의 ablation 결과, AUC는 0.9982에서 0.9972로 0.001만 하락하고 탐지율도 98.02%를 유지하였다(Table 13). 이는 모델이 tool fingerprint 외에도 frame.len, wlan.fc.type 등을 통해 공격 패턴을 학습하고 있음을 시사하며, radiotap.length 단일 피처에 대한 과적합 우려는 ablation 결과로 부분적으로 완화된다.

Table 13. radiotap.length 제거 ablation 결과 (5-Fold CV)

구성	ROC-AUC	탐지율(DR)	FPR
11 피처(radiotap.length포함)	0.9982	98.39%	3.49%
10피처(radiotap.length제거)	0.9972	98.02%	5.06%
차이 (delta)	-0.001	-0.37%p	+1.57%p

라. Adversarial Spoofing 시뮬레이션

공격자가 radiotap.length를 정상 트래픽의 최빈값(36)으로 위조하는 적대적 시나리오를 시뮬레이션하여 ML 모델의 강건성을 평가하였다. 5-Fold 교차 검증으로 학습한 모델에 대해 테스트 셋의 공격 패킷만 radiotap.length를 36으로 변조한 결과는 Table 14와 같다.

Table 14. Adversarial Radiotap Spoofing 시뮬레이션 결과

시나리오	ROC-AUC	DR(%)	FPR(%)
원본 (위조 없음)	0.9982	98.39	3.49
공격 패킷 r1→36	0.9569	67.97	3.49

Spoofing 시 탐지율이 98.39%에서 67.97%로 30.4%p 하락하여, ML 모델이 radiotap.length에 대한 높은 의존도를 가짐을 확인하였다. 그러나 하이브리드 WIPS의 규칙 기반 L1 계층은 프레임 subtype 기반 결정론적 탐지를 수행하므로, radiotap.length 위조만으로는 시스템 전체를 우회할 수 없다. 또한 Table 13의 ablation 결과(radiotap.length 제거 시 AUC 0.9972)는 모델이 보조 피처를 통해서도 상당한 탐지 능력을 유지함을 보여준다

마. 분류 모델 선택의 타당성 검증

본 연구에서 XGBoost를 최종 분류기로 선택한 근거를 검증하기 위해, 동일 11개 피처와 동일 5-Fold CV 조건에서 4종의 분류 모델을 비교 실험하였다(Table 15).

Table 15. 분류 모델별 성능 비교 (5-Fold CV, 실환경 재학습 데이터)

모델	ROC-AUC	DR(%)	FPR
XGBoost	0.9982±0.0001	98.39±0.07	3.49±0.18
Random Forest	0.9984±0.0001	97.67±0.34	1.05±1.26
LightGBM	0.9984±0.0001	98.43±0.12	3.49±0.29
Logistic Regression	0.9946±0.0001	96.97±0.07	0.08±0.03

GBDT 계열 3종(XGBoost, Random Forest, LightGBM)은 ROC-AUC 0.9982~0.9984 범위에서 거의 동일한 성능을 보이며, 모델 간 AUC 차이($\Delta AUC \leq 0.0002$)는 표준편차 (0.0001) 이내로 통계적으로 유의하지 않다. 이는 11개 프레임 구조 피처가 제공하는 분류 신호가 특정 알고리즘에 의존하지 않을 만큼 강력함을 시사한다. 반면 Logistic Regression(AUC 0.9946)은 GBDT 대비 유의미한 성능 차이를 보여, 데이터에 비선형 의사결정 경계가 존재함을 확인하였다. 최종적으로 XGBoost를 선택한 이유는 세 가지 이다. 첫째, Isotonic Calibration과의 통합이 잘 확립되어 확률 보정이 용이하다. 둘째, tree_method='hist' 기반의 효율적 추론으로 실시간 배포에 적합하다. 셋째, AWID3 오프라인 파이프라인과의 일관성을 유지할 수 있다. ROC 곡선 비교(Figure 4) 에서도 GBDT 3종은 거의 겹치는 곡선을 보이며, Logistic Regression만 저 FPR 구간 에서 상대적으로 낮은 TPR을 보인다.

V. 결론 및 제언

1. 연구 요약

본 연구는 Wi-Fi 환경의 무선 침입 방지 시스템(WIPS) 분야에서 오프라인 평가의 신뢰성 부족과 탐지-방어 간 구현 공백을 동시에 극복하는 통합 파이프라인을 제안하고 실증하였다.

탐지 모델은 AWID3 데이터셋(1,466,074건, 14클래스)을 대상으로 XGBoost에 Isotonic Calibration과 F2-Score 기반 임계치 최적화를 결합하여 ROC-AUC 0.9994, System FPR 1.43%를 달성하였다. 실환경 적용 시 Target Encoding 의존성으로 FPR ~100%가 발생하는 1차 배포 격차를 규명하였다. 이를 해소하기 위해 v5 파이프라인으로 인코딩 의존성을 제거하였으나, 이후 RF 환경 의존 피처(radiotap.channel.freq, radiotap.dbm_antsignal, radiotap.datarate)가 AP 채널 변경 및 드라이버 차이로 인한 2차 배포 격차를 유발함을 추가로 발견하였다. 이를 해소하기 위해 IEEE 802.11 프레임 구조 피처만으로 구성된 11개 안정 피처 집합으로 재설계하고 실환경 수집 트래픽으로 재학습하여 실제 배포 가능한 분류기를 확보하였다. 규칙 기반 탐지가 포착하지 못하는 공격 유형 5종을 실환경에서 직접 수집하여 11개 안정 피처로 재학습한 결과, 5-Fold CV ROC-AUC 0.9982를 달성하였다. RF 피처를 포함한 14피처 모델은 오프라인 AUC가 0.9997로 더 높았으나 실환경 FPR이 ~100%로 배포 불가능하였으며, 이는 오프라인 성능과 배포 안정성 사이의 트레이드오프를 정량적으로 보여준다. 정식 실환경 검증 실험(실험 3)에서는 활성 클라이언트 3대가 실제 트래픽을 생성하는 환경에서 MAC 랜덤화 기반 규칙 우회 공격 5종을 300초간 동시 적용하였으며, 탐지율 97.27%, FPR 0.00%, Precision 100%, 평균 탐지 지연 1.54 ms를 달성하였다. 능동적 Deauth 역주입을 통해 공격 도구의 AP 응답률을 0%로 낮추는 방어 효과를 확인하였으며, MAC 랜덤화 환경에서 MAC 블랙리스트 방식의 구조적 한계도 관찰하였다. 아울러 미학습 공격 도구(scapy)와 미학습 공격 유형(Beacon Flood, Auth Flood, Probe Flood, Association Flood)에 대해 Ground Truth 기반 정량 평가를 수행한 결과, 전 공격 유형에서 탐지율 89% 이상(Auth Flood 99.7%, Assoc Flood 98.4%, Probe Flood 93.0%, Beacon Flood 89.9%), FPR 0.60%를 달성하였다. 다만 이는 동일 소프트웨어 인젝션 생태계 내의 결과이며, 하드웨어 기반 공격 장치나 상이한 RF 환경으로의 일반화는 별도 검증이 필요하다.

2. 연구의 의의

본 연구의 기여는 새로운 알고리즘 제안이 아닌, AWID3 기반 모델의 실환경 배포 실패를 추적·분석한 엔지니어링 사례 연구로서 다음 다섯 가지다. 첫째, Target Encoding이 실환경 배포 시 FPR~100%를 유발하는 메커니즘을 사례 기반으로 분석하였다.

둘째, Target Encoding 의존성 제거(v5) 이후에도 RF 환경 의존 피처(channel.freq, dbm_antsignal, datarate)가 추가 배포 격차를 유발함을 발견하고, 11개 IEEE 802.11 프레임 구조 피처로의 재설계를 통해 실환경 FPR 0.00%를 달성하여 2단계 배포 격차 해소 경로를 제시하였다. 셋째, AWID3 기반 분석과 실환경 수집 트래픽의 이중 학습으로 규칙 우회 공격까지 탐지 범위를 확장하였다. 넷째, 제한된 실험실 환경에서 능동적 Deauth 역주입을 통한 방어 효과를 확인하고, MAC 랜덤화 공격 환경에서의 차단 메커니즘 한계를 관찰하였다. 다섯째, 학습에 사용되지 않은 공격 도구(scapy)와 미학습 공격 유형에 대해 Ground Truth 기반 평가로 전 유형 탐지율 89% 이상을 관찰하였다. 다만 이는 동일 소프트웨어 인젝션 생태계 내의 결과이며, radiotap.length 기반 ML 탐지와 신규 MAC 빈도 기반 Flood 규칙의 결합이 해당 범위 내에서 일반화를 가능하게 함을 확인하였다.

3. 한계점

본 연구의 한계는 여섯 가지로 요약된다.

첫째, Python의 GIL(Global Interpreter Lock) 제약으로 인해 4개의 워커 스레드가 실제로는 병렬이 아닌 시분할 방식으로 CPU 연산을 수행한다. 현재 트래픽 규모에서는 추론 지연이 수 ms 수준으로 충분하나, Gbps 단위의 고밀도 트래픽 환경에서는 multiprocessing 기반의 완전 병렬 아키텍처로의 전환이 필요하다. 둘째, AWID3 오프라인 모델(v5)의 피처 집합에는 ssh.direction, wlan.country_info.fnm 등 실환경 tshark 출력에서 안정적으로 추출되지 않는 필드가 포함되어 있어, 동일 모델을 그대로 실환경에 배포할 경우 성능 저하가 예상된다. 본 연구는 이를 11개 안정 피처 기반 재학습으로 해소하였으나, 해당 피처 집합이 다양한 AP 환경에서도 충분한 표현력을 가지는지는 추가 검증이 필요하다. 실제로 11개 안정 피처만으로 AWID3 데이터셋을 평가한 결과, ROC-AUC가 0.9994에서 0.9793으로 하락하고 FPR이 20.35%로 증가하여, 피처 수 축소에 따른 오프라인 분류 성능의 유의미한 손실이 확인되었다. 이는 배포 안정성 확보를 위해 감수한 트레이드오프이며, 피처 집합 확장을 통한 성능 회복이 향후 과제로 남는다. 셋째, RogueAP(1,310건)와 같이 테스트 샘플이 극소수인 클래스의 100% 탐지율은 해당 수치의 통계적 신뢰구간이 넓은 점에서 범용적 주장의 근거로 삼기에 한계가 있다. 넷째, AWID3는 단일 실험실 환경에서 한정된 공격 도구를 사용하여 생성된 데이터셋으로,

실제 현장의 다양한 트래픽 패턴과 공격 변종에 대한 일반화 성능은 추가 검증이 필요하다. 다섯째, 실험 3의 그라운드 트루스 검증에서 mdk4의 MAC 랜덤화로 인해 GT_TP=0으로, 패킷 단위 ML 예측의 정확성을 완전히 검증하지 못하였다. Table 8의 Precision 100%는 시스템 수준 차단 결정 기준으로 산출된 값이며, 개별 ML 탐지 각각이 진정한 공격 패킷인지 여부에 대한 검증은 본 실험 범위에서 수행되지 않았다. 여섯째, IV.8의 일반화 실험에서 미학습 도구에 대해 전 유형 89% 이상의 탐지율을 달성하였으나, 이는 동일 실험실 환경에서 소프트웨어 인젝션 기반 도구들을 대상으로 수행한 결과이다. Beacon-Probe Flood의 탐지율(89~93%)은 Flood 규칙의 위밍업 구간 미탐지에 기인하며, 하드웨어 기반 공격 장치나 상이한 RF 환경에서의 일반화 성능은 별도 검증이 필요하다. 본 연구의 ML 계층이 학습한 핵심 신호는 공격 행위 자체가 아닌 소프트웨어 기반 패킷 인젝션 도구 특유의 RadioTap 헤더 구조(tool fingerprint)로, 동일 인젝션 생태계(scapy, mdk4, bettercap 등) 내에서는 도구 무관 탐지를 가능하게 하지만, 하드웨어 기반 인젝션 장치나 공격자가 radiotap 헤더를 정상 NIC와 유사하게 위조하는 경우에는 탐지 실패가 예상된다. 이러한 ML 계층의 한계를 보완하기 위해 규칙 기반 계층이 프레임 구조 수준의 결정론적 탐지를 병행하며, 이는 하이브리드 아키텍처 설계의 핵심 동기이다. Adversarial spoofing 시뮬레이션에서 공격 패킷의 radiotap.length를 정상 값(36)으로 위조 시 ML 탐지율이 30.4%p 하락하였으나, 하이브리드 L1 규칙이 프레임 유형 기반으로 선행 탐지하므로 시스템 전체의 우회는 불가능하다.

4. 향후 연구 방향

향후 연구에서는 네 가지 방향으로 시스템을 고도화할 계획이다. 첫째, Python GIL의 한계를 극복하기 위해 multiprocessing 기반의 완전 병렬 처리 아키텍처를 도입하여 Gbps 수준의 트래픽에서도 실시간 추론이 가능한 시스템을 구축한다. 둘째, 지수 가중 이동 평균(EWMA) 기반의 Adaptive Thresholding 정책을 적용하여 트래픽 패턴 변화에 자동으로 대응하는 동적 임계치 조정 메커니즘을 도입한다. 셋째, AR9271 기반 자체 테스트베드에서 캡처한 실환경 무선 트래픽으로 Cross-domain 검증을 수행하여, 실험실 데이터셋에서 학습된 모델이 현실 네트워크 환경에서도 유효한 탐지 성능을 발휘하는지 확인한다. 넷째, 피처별 환경 민감도(Population Stability Index 등)를 정량화하고, 환경 불안정 피처에 대해 학습 단계에서 패널티를 부여하는 정규화 기법을 도입하여, 현재의 수동적 피처 제거를 자동화된 환경 강건 학습(Environment-Robust Learning)으로 발전시킨다.

국문요약

본 연구는 IEEE 802.11 무선 네트워크를 대상으로 하는 실시간 무선 침입 방지 시스템(WIPS)을 설계·구현하고, 실제 무선 환경에서 그 성능을 실험적으로 검증하였다. 기존 연구는 AWID3와 같은 공개 데이터셋을 활용한 오프라인 평가에 집중하여 실환경 배포 시 발생하는 성능 격차를 충분히 다루지 못하였다. 본 연구는 AWID3 기반의 초기 모델(v4)이 실환경에서 정상 트래픽 대부분을 공격으로 오분류하는 현상을 관찰하고, 그 원인을 Target Encoding 의존성에서 발생하는 훈련-배포 분포 불일치(Train-Serve Skew)로 규명하였다. 이를 해소하기 위해 모든 피처를 수치형으로 강제 변환하는 v5 파이프라인을 설계하고, 실환경 트래픽으로 재학습하는 절차를 정립하였다. 그러나 실환경 배포 과정에서 RF 환경 의존 피처(radiotap.channel.freq, radiotap.datarate, radiotap.dbm_antsignal)가 AP 채널 변경 및 드라이버 차이로 인해 학습 시점과 상이한 값을 가지며 추가적인 배포 격차를 유발함을 발견하였다. 이를 해소하기 위해 RF 환경 피처를 배제하고 IEEE 802.11 프레임 구조 피처만으로 구성된 11개 피처 집합으로 재설계하였다. 또한 규칙 기반 탐지와 XGBoost 기반 ML 보조 탐지를 계층적으로 결합한 하이브리드 방어 엔진을 구현하였으며, 슬라이딩 윈도우 기반 의사결정 엔진을 도입하였다. AWID3 데이터셋에 대한 5-Fold 교차 검증에서 ROC-AUC 0.9994, System FPR 1.43%를 달성하였다. L2 무선 프레임 피처로 탐지 가능한 11개 공격 유형 전체에서 탐지율 90% 이상을 기록하였으며, L7 응용 계층 공격(SQL_Injection)은 탐지 범위 외로 구분하고 Disas는 규칙 기반 계층이 전담한다. 실제 AP를 대상으로 수행한 실환경 공격 실험에서는 FPR 0.00%, Precision 100%, 평균 탐지 지연 0.16~1.54 ms(실험 조건별)로 실시간 대응 가능성을 확인하였다. 또한 학습에 사용하지 않은 공격 도구(scapy)와 미학습 공격 유형(Beacon Flood, Auth Flood, Probe Flood, Association Flood)에 대해 Ground Truth 기반 평가를 수행한 결과, 전 공격 유형에서 탐지율 89% 이상, FPR 0.60%를 달성하여 동일 소프트웨어 인젝션 생태계 내에서의 일반화 가능성을 관찰하였다. 다만 본 실험은 활성 클라이언트가 제한된 단일 채널 환경에서 수행되었으므로 결과의 일반화에는 추가 검증이 필요하다.

주제어: 무선 침입 방지 시스템(WIPS), XGBoost, AWID3, 실시간 능동 방어, 배포 격차, MAC 랜덤화

References

- Bellardo, J., & Savage, S. (2003). 802.11 denial-of-service attacks: Real vulnerabilities and practical solutions. *Proceedings of the 12th USENIX Security Symposium*, 15–28.
- Chatzoglou, E., Kambourakis, G., & Kolias, C. (2021). Empirical evaluation of attacks against IEEE 802.11 enterprise networks: The AWID3 dataset. *IEEE Access*, 9, 34188–34205.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804.
- Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1137–1143.
- Kolias, C., Kambourakis, G., Stavrou, A., & Gritzalis, S. (2016). Intrusion detection in 802.11 networks: Empirical evaluation of threats and a public dataset. *IEEE Communications Surveys & Tutorials*, 18(1), 184–208.
- Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, 625–632.
- Scarfone, K., & Mell, P. (2007). *Guide to Intrusion Detection and Prevention Systems (IDPS) (NIST Special Publication 800-94)*. National Institute of Standards and Technology.
- Souppaya, M., & Scarfone, K. (2012). *Guidelines for Securing Wireless Local Area Networks (WLANs) (NIST Special Publication 800-153)*. National Institute of Standards and Technology.
- van Rijsbergen, C. J. (1979). *Information retrieval* (2nd ed.). Butterworths.
- Vanhoef, M., & Piessens, F. (2017). Key reinstallation attacks: Forcing nonce reuse in WPA2. *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS)*, 1313–1328.
- Pendlebury, F., Pierazzi, F., Jordaney, R., Kinder, J., & Cavallaro, L. (2019). TESSERACT: Eliminating experimental bias in malware classification across space and time. *Proceedings of the 28th USENIX Security Symposium*, 729–746.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.

저자정보
이성현